



Tecnológico de Monterrey

Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Estado de México, Escuela de Ingeniería y Ciencias.

TC1002S. Herramientas computacionales: el arte de la analítica

Grupo 201

Profesor:

Aram Baruch González Pérez

Actividad Evaluable: Limpieza de datos

Estudiantes:

Jennyfer Nahomi Jasso Hernández	A01749898
Min Che Kim	A01750338
Michelle Rergis Novelo	A01798576

Fecha de entrega:

24 de Octubre de 2024

Reporte de Limpieza de Datos

Resumen

El proceso de limpieza de datos es crucial para asegurar que el análisis y las decisiones basadas en los datos sean precisos y confiables. Los datos sin procesar a menudo contienen errores, valores faltantes, duplicados o información irrelevante, lo que puede conducir a conclusiones incorrectas o sesgadas. Un conjunto de datos limpio también facilita su interpretación y análisis, permitiendo obtener perspectivas significativas.

En el presente documento se describe el proceso de limpieza del conjunto de datos relacionado con compradores de bicicletas, el cual incluyó la eliminación de columnas irrelevantes para el análisis, el tratamiento de valores faltantes en varias columnas, y la corrección de registros duplicados. Particularmente, en la columna *Income* se reemplazaron los valores nulos con la mediana, media o moda según la variable. Además, se identificaron y eliminaron filas duplicadas basadas en el campo *ID* para garantizar la unicidad de los registros. El objetivo de este proceso fue mejorar la calidad de los datos al eliminar inconsistencias y ruido, proporcionando así un conjunto de datos confiable y listo para su análisis posterior.

1. Introducción

Este informe documenta el proceso de limpieza de un conjunto de datos sobre compradores de bicicletas, que contiene información demográfica y socioeconómica.

1.1. Conjunto de Datos

El conjunto de datos cuenta con 1,251 entradas y 13 columnas, proporcionando información clave como el estado civil, género, ingresos,

cantidad de hijos, nivel educativo, ocupación, propiedad de vivienda, número de automóviles, distancia de desplazamiento, región, edad y la decisión de comprar o no una bicicleta. Todos estos datos están almacenados en un archivo CSV.

1.2. Objetivos de la Limpieza

El objetivo principal fue preparar los datos para su análisis posterior. Para esto se realizaron acciones como:

- **Estandarizar formatos:** Especialmente en la columna de *Income*, donde los valores contenían comas que impedían su uso como números.
- **Eliminar duplicados:** Se encontraron registros duplicados que podrían distorsionar el análisis.
- **Corregir valores faltantes:** Varios campos presentaban valores nulos, lo que afectaba la integridad de los datos.

2. Exploración Inicial

Antes de comenzar con el proceso de limpieza, se realizó una exploración inicial del conjunto de datos con el fin de identificar problemas potenciales que afectan su calidad. Para ello, se utilizó la función `info()` de Pandas para obtener un resumen general de los datos, lo cual permitió detectar valores nulos en varias columnas. Sugiriendo la necesidad de imputación de estos datos faltantes. Del mismo modo, se identificó la presencia de registros duplicados basados en el campo *ID*, sabiendo que este campo es único. Esta inspección también mostró que la columna “Income” contenía valores numéricos con comas, lo que dificultaba su procesamiento matemático.

3. Proceso de Limpieza

3.1. Tratamiento de Valores Faltantes

El conjunto de datos presentaba valores faltantes en varias columnas, lo que comprometía la precisión del análisis. Las decisiones para manejar estos valores se tomaron en función del tipo de variable:

- **Columnas numéricas (*Income, Children, Cars, Age*):** En las columnas *Income, Cars* y *Age*, se reemplazaron los valores faltantes utilizando la mediana debido a la presencia de valores atípicos. Se decidió no utilizar la media para evitar que estos valores extremos influyeran en los resultados. En contraste, para la columna *Children*, se decidió utilizar la media, dado que no se identificaron valores atípicos significativos en esta variable.
- **Columnas categóricas (*Marital Status, Gender, Education, Occupation, Home Owner, Commute Distance, Region, Purchased Bike*):** Los valores faltantes en las columnas categóricas, se completaron utilizando la moda de cada columna. Esta decisión se tomó para mantener la mayor cantidad de datos sin alterar la distribución original de las categorías.

3.2. Eliminación de duplicados

Durante la exploración inicial, se detectaron registros duplicados en el campo *ID*, lo que sugería la presencia de datos repetidos. Estos duplicados podría sesgar los resultados del análisis, por lo que se decidió eliminarlos con la función `drop_duplicates()` de Pandas. Esto redujo el número total de filas de 1,251 a 1,000, asegurando que cada registro representará una entrada única y válida.

3.3. Corrección de Datos Erróneos

- **Columna *Income*:** Se eliminaron las comas en los valores numéricos utilizando la función `str.replace()` de Pandas, lo que permitió convertir los valores a formato numérico (float) utilizando `pd.to_numeric()`.
- **Revisión de tipos de datos:** Se utilizó la función `info()` para corroborar que las variables numéricas, como *Income* y *Age*, estuvieran correctamente asignadas como numéricas, y que las columnas categóricas, como *Marital Status* y *Occupation*, estuvieran en formato de texto.
- **Verificación de categorías:** Se utilizó `value_counts()` para verificar la frecuencia de cada categoría y detectar posibles errores en el formato de escritura o en valores de las categorías.

3.4. Manejo de Valores Atípicos

Utilizando la función `describe()` de Pandas, se generaron estadísticas descriptivas para todas las variables numéricas, lo que permitió identificar valores atípicos. Las siguientes columnas mostraron valores que se encontraban significativamente alejados del rango esperado:

- **Columnas *Income*, *Cars*, *Age*:** Aunque se identificaron algunos valores atípicos en estas columnas, se decidió mantenerlos en el conjunto de datos, ya eran muy pocos y podrían considerarse para un análisis más detallado.
- **Columna *Children*:** No se identificaron valores atípicos en esta columna; todos los rangos se encontraban dentro de un rango lógico.

3.5. Estandarización y Normalización

No se realizó ninguna estandarización en este conjunto de datos.

Inicialmente, se consideró convertir la columna *Commute Distance* a un formato numérico, pero finalmente se optó por mantenerla como una variable categórica en su formato original.

4. Resultados

Después de completar el proceso de limpieza, se mejoró significativamente la calidad del conjunto de datos. Los resultados del proceso de limpieza fueron los siguientes:

4.1. Estadísticas Descriptivas

Antes de la limpieza:

- Número de registros: 1,251
- Número de columnas con valores faltantes: 7 columnas
- Duplicados: 251 registros con IDs duplicados

Datos faltantes por columna:	
ID	0
Marital Status	7
Gender	13
Income	8
Children	13
Education	0
Occupation	0
Home Owner	4
Cars	9
Commute Distance	0
Region	0
Age	13
Purchased Bike	0
dtype: int64	

Información del DataFrame:			
<class 'pandas.core.frame.DataFrame'>			
RangeIndex: 1251 entries, 0 to 1250			
Data columns (total 13 columns):			
#	Column	Non-Null Count	Dtype
0	ID	1251 non-null	int64
1	Marital Status	1244 non-null	object
2	Gender	1238 non-null	object
3	Income	1243 non-null	object
4	Children	1238 non-null	float64
5	Education	1251 non-null	object
6	Occupation	1251 non-null	object
7	Home Owner	1247 non-null	object
8	Cars	1242 non-null	float64
9	Commute Distance	1251 non-null	object
10	Region	1251 non-null	object
11	Age	1238 non-null	float64
12	Purchased Bike	1251 non-null	object
dtypes: float64(3), int64(1), object(9)			
memory usage: 127.2+ KB			

Después de la limpieza:

- Número de registros: 1,000
- Número de columnas con valores faltantes: 0
- Duplicados: Eliminados todos los duplicados

Datos nulos después de la limpieza:		<class 'pandas.core.frame.DataFrame'>		
ID	0	Index: 1000 entries, 0 to 1249		
Marital Status	0	Data columns (total 13 columns):		
Gender	0	#	Column	Non-Null Count Dtype
Income	0	---	-----	----
Children	0	0	ID	1000 non-null int64
Education	0	1	Marital Status	1000 non-null object
Occupation	0	2	Gender	1000 non-null object
Home Owner	0	3	Income	1000 non-null float64
Cars	0	4	Children	1000 non-null float64
Commute Distance	0	5	Education	1000 non-null object
Region	0	6	Occupation	1000 non-null object
Age	0	7	Home Owner	1000 non-null object
Purchased Bike	0	8	Cars	1000 non-null float64
dtype: int64		9	Commute Distance	1000 non-null object
		10	Region	1000 non-null object
		11	Age	1000 non-null float64
		12	Purchased Bike	1000 non-null object
		dtypes: float64(4), int64(1), object(8)		
		memory usage: 109.4+ KB		

4.2. Distribución de Datos

Antes del proceso de limpieza, la variable *Income* y *Age* mostraba una distribución con algunos valores atípicos en el rango superior, que podrían distorsionar los resultados del análisis hecho. Sin embargo, dado que estos valores no eran recurrentes y podrían aportar información valiosa en futuros análisis, no se realizó su eliminación. Por lo tanto, aunque se imputaron los valores faltantes en columnas como *Income*, *Children* y *Age*, la distribución general de estas variables no cambió de manera significativa después de la limpieza, ya que no se realizó la eliminación de los valores atípicos.

5. Conclusiones

El proceso de limpieza mejoró de manera considerable la calidad general del

conjunto inicial de datos, permitiendo la imputación de valores faltantes y la eliminación de duplicados sin alterar significativamente la distribución original de las variables numéricas. Además, los valores atípicos fueron conservados, dado que no eran recurrentes y se consideró que podrían aportar a un análisis más realista y completo.

Gracias al proceso realizado, el conjunto de datos es apto para realizar un análisis, garantizando la integridad y confiabilidad, sin perder la riqueza de información que los valores atípicos podrían proporcionar.

6. Recomendaciones

Algunas recomendaciones para un mejor proceso de la limpieza de datos, son las siguientes:

- **Eliminación de valores atípicos:** Aunque en este proceso no se eliminaron estos valores, es recomendable realizar un análisis más detallado para visualizar el impacto que estos tienen en las estadísticas y en caso de que afecte las mismas hacer su eliminación.
- **Convertir el formato de la columna Comte Distance:** En esta columna se maneja un rango de distancia, consideramos que este se podría modificar y convertir en valor numérico para un análisis estadístico más preciso.
- **Automatización del proceso de limpieza:** El desarrollo de scripts que puedan servir para casos generales del proceso de limpieza, incluyendo la detección y el manejo de valores atípicos, esto con el objetivo de agilizar el procesamiento de datos.

7. Referencias

Build software better, together. (2024). GitHub. <https://github.com/>

González Pérez, A. B. (2024). Estadística descriptiva [Presentación]. Tecnológico de Monterrey, Campus Estado de México.

González Pérez, A. B. (2024). Limpieza de datos [Presentación]. Tecnológico de Monterrey, Campus Estado de México.

González Pérez, A. B. (2024). Selección y filtrado de datos [Presentación]. Tecnológico de Monterrey, Campus Estado de México.

Google Colab. (2019). Google.com. <https://colab.research.google.com/>

Microsoft. (Noviembre 3, 2021). Visual Studio Code. Visualstudio.com; Microsoft. <https://code.visualstudio.com/>

Project Jupyter. (2024). Jupyter.org. <https://jupyter.org/>